


局部加权线性回归

对于正常的一般线性回归我们的损失函数通常是考虑所有的点的损失平方之和，但面对形状并不太符合线性的实际情况时，再套线性回归似乎不是太好。例如这样：

Housing price prediction.



这时候我们发现很难用一条直线可以完美拟合实际线条形状。

从另一个角度想，对于实际中的数据其分布总是与周围的数据点分布相关联的，至少大部分时候不会偏差太大。因此我们的损失函数是不是可以对不同位置的点做个加权呢？

例如我们可以在离目标预测数据点 x_i 附近的点的损失函数加上更强的权重，而对于距离较远的点，我们不关注它。因此新的损失函数可以表示为：

$$Loss = \sum_i^m L(x_i * w_i)$$

其中 w_i 是针对每个数据点的损失加的权重，通常计算方法是这样：

$$w^{(i)} = \exp\left(-\frac{(x^{(i)} - x)^2}{2k^2}\right)$$

概率和似然的区别

对于一个模型，如果参数 θ 是固定的而根据不同给定的 x 会有不同的输出，这时候我们讨论输出 y 的性质是概率。而反过来如果输入是固定的而参数 θ 是不定的那么我们说这时候考虑的输出的性质是似然。

MLE

MLE即最大似然估计，依据刚才的定义，既然是“似然”，那么我们所要做的就是找到一组参数 θ 令得到对应输出的概率最大。通常而言我们在模型中所用的损失函数形式会转化成MLE，这样数学性质计算比较方便。

logistic regression

逻辑回归通常用于分类问题，输出被限定在一个属于 $[0, 1]$ 之间的范围，所用的输出限制是：

$$g(z) = \frac{1}{1+e^{-z}}$$

这就是sigmoid函数。

对于分类问题我们的结果似然是：

$$\prod_i (h_{\theta}(x)^{y_i} (1 - h_{\theta}(x))^{1-y_i})$$

我们的目的就是取MLE，因此得到对数似然估计：

$$L(\theta) = \sum_i y_i \log(h_{\theta}(x_i)) + (1 - y_i) \log(1 - h_{\theta}(x_i))$$

现在取极大对数似然， θ 参数的更新方式是：

$$\theta_j = \theta_j + \alpha \frac{\partial L(\theta)}{\partial \theta_j}$$

对于之前的线性回归方式，拟合参数 θ 的方法一直是梯度下降法，但是对于求MLE，所使用的方法是梯度上升法。